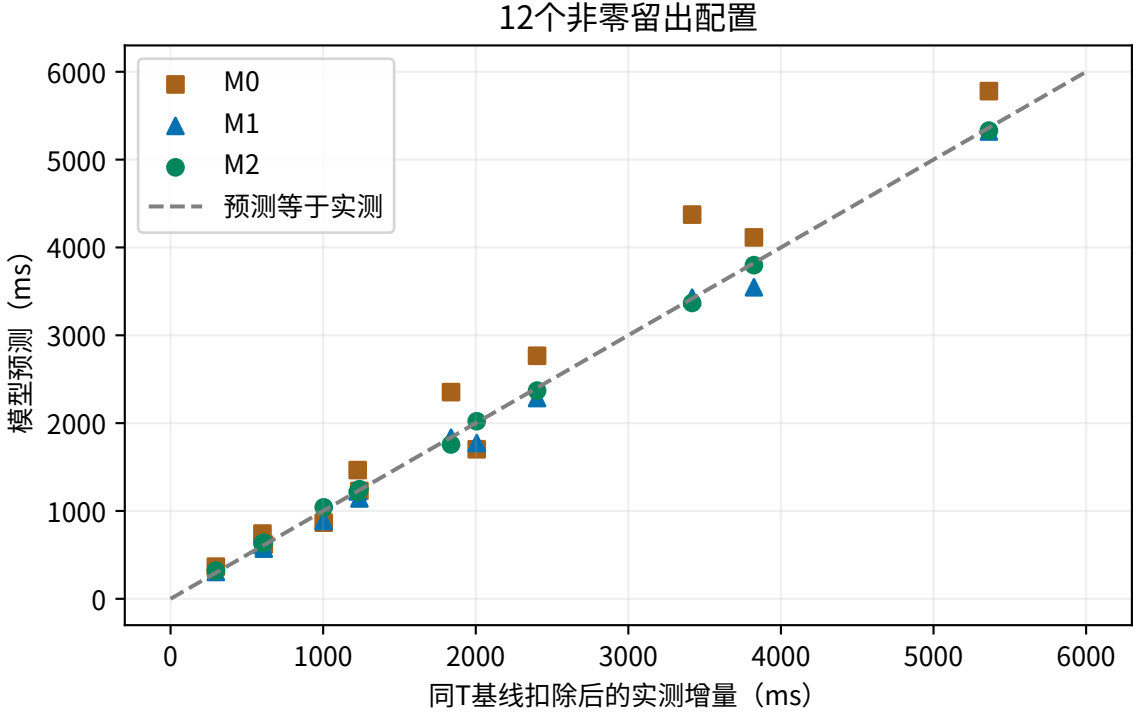
12个非零留出配置
M0
M1
M2
预测等于实测
模型预测（ms）
同T基线扣除后的实测增量（ms）
0
1000
2000
3000
4000
5000
6000

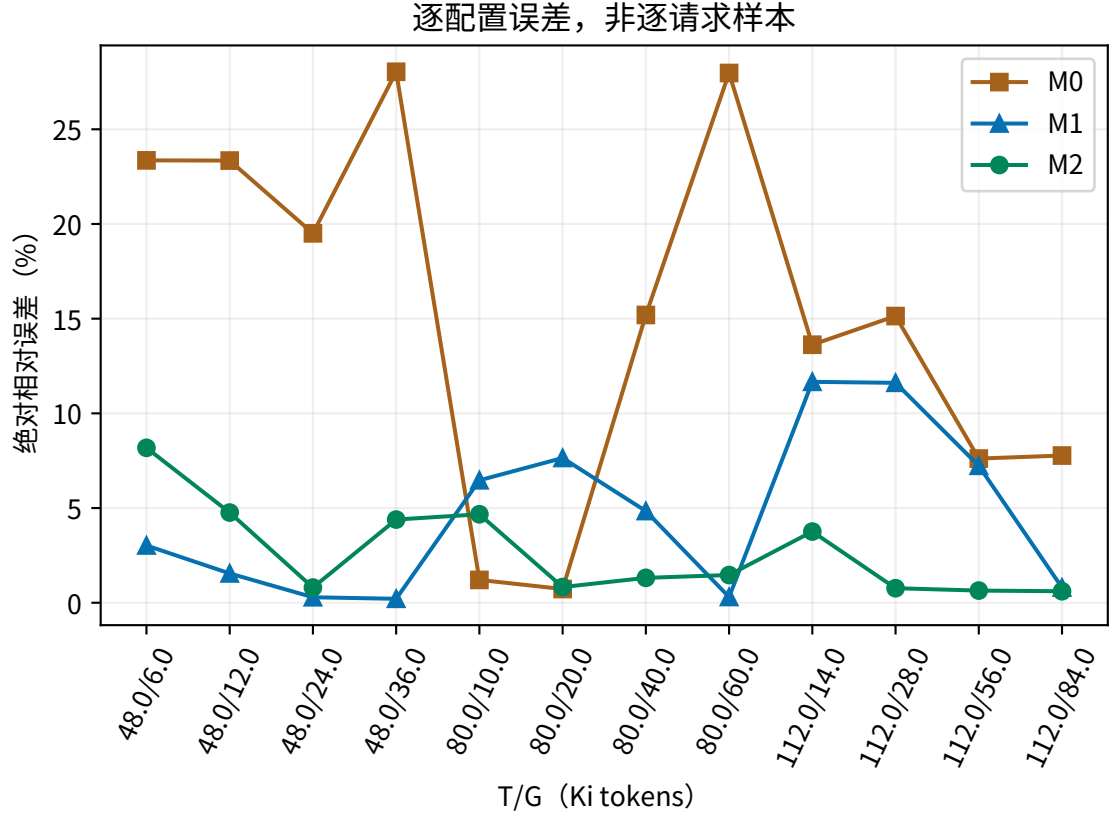
逐配置误差，非逐请求样本
M0
M1
M2
绝对相对误差（%）
T/G（Ki tokens）
0
5
10
15
20
25
48.0/6.0
48.0/12.0
48.0/24.0
48.0/36.0
80.0/10.0
80.0/20.0
80.0/40.0
80.0/60.0
112.0/14.0
112.0/28.0
112.0/56.0
112.0/84.0